

2. Denoising Diffusion Probabilistic Models

원본 이미지에 작은 Gaussian noise를 계속 추가하면 결국 이미지의 정보가 거의 사라지고 일반적인 Gaussian noise와 비슷한 상태가 된다. 이 논문에서는 이 noise 추가 과정의 반대 방향을 신경망이 학습하도록 만든다.

Diffusion model은 크게 forward process와 reverse process로 나눌 수 있다. Forward process는 실제 이미지 x_0 에 조금씩 Gaussian noise를 추가하는 과정이다. 이 과정은 학습하지 않고 미리 정해 놓는다. 반면 reverse process는 noise가 섞인 이미지 x_t 에서 조금 더 깨끗한 상태인 x_{t-1} 을 복원하는 과정이며, 이 부분을 신경망으로 학습한다.

Forward process에서는 매 timestep마다 작은 noise가 추가된다. 논문에서는 $\alpha_t = 1 - \beta_t$

라고 정의하고, $\alpha_t = \prod_{s=1}^t \alpha_s$

를 사용한다.

이렇게 하면 임의의 timestep t 에서의 x_t 를 다음 식으로 한 번에 만들 수 있다. $x_t = \alpha_t x_0 + \sqrt{1 - \alpha_t} \epsilon$

여기서 $\epsilon \sim N(0, I)$

이다.

이 식이 중요한 이유는 학습할 때 $x_1, x_2, \dots, x_{t-1}, x_t$ 를 실제로 하나씩 순서대로 만들 필요가 없기 때문이다. 원본 이미지 x_0 , timestep t , noise ϵ 만 있으면 바로 x_t 를 계산할 수 있다.

Reverse process에서는 현재 noisy image x_t 를 보고 이전 단계의 분포 $p_\theta(x_{t-1} | x_t)$

를 학습한다. 처음에는 네트워크가 reverse process의 평균 μ_θ 를 직접 예측하는 구조로 생각할 수 있지만, 이 논문에서는 실제로 이미지에 추가되었던 noise ϵ 를 예측하는 parameterization을 사용한다. 즉 네트워크는 $\epsilon_\theta(x_t, t)$

를 출력한다.

논문에서는 이 ϵ -prediction 방식이 denoising score matching과 연결된다는 것을 설명한다. 또한 복잡한 variational bound를 간단한 noise prediction 문제로 바꿀 수 있다. 실제로 사용한 simplified objective는 다음과 같다. $L_{\text{simple}} = E_{t, x_0, \epsilon} [\|\epsilon - \epsilon_\theta(\alpha_t x_0 + \sqrt{1 - \alpha_t} \epsilon, t)\|^2]$

$L_{\text{simple}} = E_{t, x_0, \epsilon} [\|\epsilon - \epsilon_\theta(\alpha_t x_0 + \sqrt{1 - \alpha_t} \epsilon, t)\|^2]$

이 식은 생각보다 단순하다. 학습할 때 내가 직접 이미지에 넣은 noise ϵ 이 있고, 신경망이 예측한 noise ϵ_θ 가 있다. 이 둘의 차이를 MSE로 줄이는 것이다.

학습 과정을 단순하게 정리하면 다음과 같다.

원본 이미지 x_0 를 하나 선택하고, 1부터 T 사이의 timestep t 를 랜덤하게 선택한다. 그 다음 Gaussian noise ϵ 을 하나 뽑고 위 식을 이용하여 x_t 를 만든다. 모델은 x_t 와 timestep t 를 입력받아 현재 이미지에 포함되어 있는 noise를 예측한다. 그리고 실제 noise와 예측한 noise의 차이를 최소화한다. 논문의 Algorithm 1도 이 과정을 그대로 나타낸다.

생성 과정은 학습과 반대이다. 먼저 $x_T \sim N(0, I)$

에서 완전한 noise를 하나 만든다.

그 다음 $x_T \rightarrow x_{T-1} \rightarrow x_{T-2} \rightarrow \dots \rightarrow x_0$ $\rightarrow x_T \rightarrow x_{T-1} \rightarrow x_{T-2} \rightarrow \dots \rightarrow x_0$

순서로 조금씩 noise를 제거한다. 각 단계에서는 신경망이 예측한 $\epsilon_\theta(x_t, t)$ 를 이용하여 이전 상태를 계산한다. 논문의 Algorithm 2가 이 sampling 과정을 설명한다.

실험에서는 $T=1000$ 을 사용했다. Forward process의 β_t 는 10^{-4} 에서 0.02 까지 선형적으로 증가하도록 설정하였다. Reverse process의 신경망은 U-Net 계열 구조를 사용하고 group normalization을 적용했다. 또한 timestep 정보를 네트워크에 전달하기 위해 Transformer에서 사용되는 sinusoidal position embedding을 사용하였고, 16×16 feature map에서 self-attention을 적용하였다.

CIFAR-10 실험에서 이 논문의 diffusion model은 Inception Score 9.46 ± 0.11 , FID 3.17 을 기록하였다. 특히 논문에서 제안한 ϵ -prediction과 L_{simple} 조합이 좋은 sample quality를 보였다.

Ablation에서도 reverse process에서 어떤 값을 예측하는지가 중요하게 나타났다. Reverse mean $\mu \sim \tilde{\mu}$ 를 직접 예측하는 방식과 ϵ 을 예측하는 방식을 비교하였고, variance를 직접 학습하는 경우에는 학습이 불안정하거나 sample quality가 떨어지는 결과가 나타났다. 반면 ϵ -prediction은 simplified objective와 함께 사용했을 때 좋은 결과를 보였다.

또 흥미로운 부분은 likelihood와 sample quality의 차이이다. 논문에서는 true variational bound로 학습했을 때 codelength 측면에서는 더 좋은 결과를 얻지만, simplified objective를 사용했을 때 생성 이미지의 품질이 더 좋았다고 한다. 즉 확률모델의 likelihood를 더 잘 맞추는 것과 사람이 보기에 좋은 이미지를 만드는 것이 완전히 같은 목표는 아니라는 것을 확인할 수 있다.

정리하면 DDPM은 이미지에 noise를 넣는 forward process는 고정해 두고, 그 noise를 다시 제거하는 reverse process를 신경망으로 학습하는 생성 모델이다. 이 논문에서 특히 중요한 부분은 reverse process의 평균을 직접 예측하는 대신 추가된 noise ϵ 을 예측하도록 문제를 바꾸고, 이를 단순한 MSE loss로 학습할 수 있게 만든 점이다. 이 방식으로 당시 매우 높은 품질의 이미지 생성 결과를 보여주었다.