

Genie: Generative Interactive Environments

1. Introduction

기존 영상 생성 모델은 새로운 영상을 만들 수 있지만, 사용자가 행동을 입력하며 지속적으로 조작하기는 어렵다. 반대로 기존 world model은 보통 영상과 실제 행동이 함께 기록된 데이터가 필요하다.

Genie는 “행동 라벨이 없는 인터넷 영상만으로도 사용자가 조작할 수 있는 환경을 만들 수 있는가?” 라는 문제를 다룬다. 영상 속 프레임 변화를 이용해 행동을 스스로 추론하고, 이를 다음 장면 생성에 활용한다.

2. Method

Genie는 크게 Latent Action Model, Video Tokenizer, Dynamics Model로 구성된다.

Latent Action Model(LAM)은 이전 프레임과 다음 프레임의 변화를 보고 잠재 행동을 추론한다. 행동은 사람이 미리 정의한 왼쪽, 오른쪽, 점프 같은 라벨이 아니라 8개의 이산 latent action으로 학습된다.

Video Tokenizer는 영상을 작은 이산 토큰으로 압축한다. 영상 토큰은 현재 장면을 표현하고, latent action은 프레임 사이의 변화를 표현한다.

Dynamics Model은 과거 영상 토큰과 latent action을 입력받아 다음 프레임의 영상 토큰을 예측한다. 이를 통해 같은 시작 화면이라도 사용자가 어떤 행동을 선택하느냐에 따라 다음 장면이 달라진다.

3. Inference

실제 사용 시에는 시작 이미지를 영상 토큰으로 변환한 뒤, 사용자가 0~7 중 하나의 행동을 선택한다. Dynamics Model은 해당 행동을 조건으로 다음 프레임을 생성하고, 이 과정을 반복하면서 환경을 조작한다.

즉 학습 중에는 영상에서 행동을 추론하지만, 실제 실행 시에는 사용자가 latent action을 직접 선택하는 구조다.

4. Experimental Results

Genie는 주로 대규모 2D 플랫폼 게임 영상으로 학습되었다. 모델 규모를 키울수록 Dynamics Model의 학습 성능이 개선되었고, 최종적으로 약 11B 규모까지 확장되었다.

또한 생성 이미지, 손그림, 실제 사진처럼 학습 데이터와 다른 시작 이미지에서도 게임과 비슷한 움직임을 생성하는 결과를 보였다.

LAM 입력에 대한 실험에서는 원본 픽셀을 사용할 경우 영상 토큰을 사용할 때보다 제어성 지표인 Δ PSNR이 더 높게 나타났다. 이는 토큰화 과정에서 움직임과 관련된 정보 일부가 손실될 수 있음을 보여준다.

5. Agent 활용

Genie에서 학습한 latent action은 에이전트 학습에도 활용할 수 있다. 전문가 영상에 latent action을 붙인 뒤 이를 이용해 정책을 학습하고, 소량의 실제 행동 라벨을 사용해 latent action과 실제 행동을 연결한다.

따라서 실제 행동 라벨을 완전히 사용하지 않는 것은 아니지만, 대부분의 행동 정보를 영상 자체에서 학습할 수 있다는 점이 중요하다.

6. Conclusion

Genie의 핵심은 행동 정보가 없는 영상에서도 프레임 변화로부터 행동을 학습하고, 그 행동을 이용해 사용자가 조작 가능한 환경을 생성할 수 있다는 것이다.

다만 긴 시간 동안 환경의 일관성을 유지하기 어렵고, 논문 당시 생성 속도도 약 1FPS 수준이라는 한계가 있다.

핵심 정리:

Genie = 영상에서 latent action을 발견하고, 그 action으로 다음 장면을 생성하는 generative world model