

V-JEPA 2: Self-Supervised Video Models Enable Understanding, Prediction and Planning

1. Introduction

로봇의 행동 결과를 학습하려면 많은 상호작용 데이터가 필요하지만, 실제 로봇 데이터를 대규모로 수집하는 것은 비용이 크다. 반면 인터넷에는 행동 라벨은 없지만 다양한 영상 데이터가 존재한다.

V-JEPA 2는 인터넷 영상을 이용해 세상의 움직임과 구조를 먼저 학습하고, 이후 적은 로봇 데이터로 행동의 효과를 추가 학습하는 방식을 제안한다.

2. V-JEPA 2

V-JEPA 2의 핵심은 미래의 픽셀을 직접 생성하는 것이 아니라 representation을 예측하는 것이다.

영상 일부를 가린 뒤 encoder는 보이는 부분만 처리하고, predictor는 가려진 부분의 representation을 예측한다. 정답 representation은 전체 영상을 본 EMA encoder가 제공한다.

따라서 모델은 화면의 세세한 픽셀을 복원하기보다는 물체의 위치, 움직임, 상태 변화처럼 미래 예측에 필요한 특징을 학습하게 된다.

기존 V-JEPA보다 데이터, 모델 크기, 입력 프레임 수와 해상도를 크게 확장했으며, 100만 시간 이상의 영상 데이터를 활용한다.

3. V-JEPA 2-AC

기본 V-JEPA 2는 영상의 움직임은 이해할 수 있지만, 특정 행동을 했을 때 어떤 결과가 나오는지 직접 알지 못한다.

이를 위해 V-JEPA 2의 encoder를 고정하고, 새로운 action-conditioned predictor를 추가한다. 이 모델이 V-JEPA 2-AC다.

입력은 과거 영상의 representation + 로봇 상태 + 행동이고, 출력은 해당 행동 이후의 미래 representation이다.

이 과정에는 62시간 미만의 DROID 로봇 데이터를 사용한다.

4. Planning

로봇을 제어할 때는 현재 이미지와 목표 이미지를 각각 representation으로 변환한다.

여러 후보 행동을 적용했을 때의 미래 representation을 예측하고, 목표 representation과 가장 가까워지는 행동을 선택한다.

행동 탐색에는 CEM, 실행에는 MPC를 사용한다. 즉 여러 행동을 미리 계획하더라도 실제로는 첫 번째 행동만 수행하고, 새로운 상태를 관측한 뒤 다시 계획한다.

5. Experimental Results

V-JEPA 2-AC는 학습 데이터를 직접 수집하지 않은 새로운 두 실험실의 Franka 로봇에서도 물체 잡기와 옮기기 작업을 수행했다.

또한 V-JEPA 2의 representation은 영상 이해에도 활용되었다. Something-Something v2에서는 77.3% Top-1 accuracy, Epic-Kitchens-100 행동 예측에서는 mean-class Recall@5 39.7을 기록했다.

영상 생성 기반 모델과 비교한 실험에서는 특정 설정에서 행동 하나를 계획하는 데 Cosmos는 약 4분, V-JEPA 2-AC는 약 16초가 걸렸다. 이는 미래 영상을 직접 생성하지 않고 representation 공간에서 계획하는 방식의 계산 효율성을 보여준다.

6. Limitation

V-JEPA 2-AC는 카메라 위치 변화에 민감하며, 긴 planning에서는 미래 예측 오차가 누적될 수 있다.

또 현재 로봇 제어는 주로 목표 이미지를 사용하며, 장기적인 작업이나 자연어 명령을 이용한 planning은 아직 추가 연구가 필요한 부분이다.

7. Conclusion

V-JEPA 2의 핵심은 대규모 영상에서 세상의 움직임을 representation 형태로 먼저 학습하고, 소량의 행동 데이터를 이용해 행동에 따른 미래를 예측하도록 확장하는 것이다.

이를 통해 영상 이해뿐 아니라 실제 로봇의 행동 계획까지 연결할 수 있음을 보여준다.

핵심 정리:

V-JEPA 2 = 영상으로 세계의 representation을 학습하고, 행동에 따른 미래 representation을 예측해 planning에 사용하는 world model